

МИНОБРНАУКИ РОССИИ  
Федеральное государственное бюджетное  
образовательное учреждение высшего образования  
«Тульский государственный университет»  
Кафедра информационной безопасности

УТВЕРЖДАЮ  
Зав. кафедрой ИБ  
\_\_\_\_\_ А.А. Сычугов  
«\_\_» \_\_\_\_\_ 20\_\_ г.

## ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

к курсовой работе по дисциплине  
«Теория вероятностей и математическая статистика»  
на тему

«Случайные величины. Распределение Стьюдента (t-распределение)»

Автор работы \_\_\_\_\_ студент гр. 230711 Павлова В.С.  
(дата, подпись) (фамилия и инициалы)

Руководитель работы \_\_\_\_\_  
(дата, подпись) (должность) (фамилия и инициалы)

Работа защищена \_\_\_\_\_ с оценкой \_\_\_\_\_  
(дата)

Члены комиссии \_\_\_\_\_  
(дата, подпись) (должность) (фамилия и инициалы)

\_\_\_\_\_ (дата, подпись) (должность) (фамилия и инициалы)

\_\_\_\_\_ (дата, подпись) (должность) (фамилия и инициалы)

Тула 2023

# ЗАДАНИЕ

на курсовую работу по дисциплине

«Теория вероятностей и математическая статистика»

студента гр. 230711 Павловой Виктории Сергеевны

Тема курсовой работы

«Случайные величины. Распределение Стьюдента (t-распределение)»

Исходные данные

Задание получил \_\_\_\_\_  
(ФИО) (подпись)

Задание выдал \_\_\_\_\_  
(ФИО) (подпись)

Дата выдачи задания 21.02.2023 г.

График выполнения КР 21.02-28.02 – Получение и ознакомление с заданием

01.03-22.03 – Изучение литературы и других исходных материалов

23.03-03.05 – Изучение теории, раскрывающей тему курсовой работы

04.05-17.05 – Реализация практической части курсовой работы

18.05-24.05 – Анализ результатов

25.05-07.06 – Оформление пояснительной записки и сдача на проверку

28.06.2023 – Защита курсовой работы

Рекомендации и особые отметки \_\_\_\_\_

«\_\_» \_\_\_\_\_ 20\_\_ г

# Содержание

Введение .....	4
1 Случайная величина и её характеристики .....	6
1.1 Одномерная случайная величина .....	6
1.2 Основные виды распределения случайных величин.....	10
1.3 Распределение Стьюдента .....	13
2 Применение t-распределения при решении практических задач.....	20
2.1 Оценка среднего значения генеральной совокупности.....	21
2.2 Использование t-распределения для вычисления вероятности.....	22
2.3 Задача об оценке статистической значимости (анализ регрессии).....	23
2.4 Проверка гипотезы о среднем значении показателя в генеральной совокупности .....	25
2.5 Задача о проверке гипотезы о значимости коэффициента регрессии .	25
Заключение .....	27
Список использованных источников .....	28

## Введение

Математическая дисциплина, которая изучает случайные явления и вероятности их возникновения, называется теорией вероятностей. Она имеет широкий спектр применений, начиная от криптографии и финансовой аналитики и заканчивая разработками в сфере искусственного интеллекта. История теории вероятностей уходит в далекое прошлое, и её основоположником считается математик Блез Паскаль. В 1654 году он начал свои исследования вероятностей, решая задачу о разделе выигрыша в азартной игре.

За несколько сотен лет теория вероятностей развилась в самостоятельную научную дисциплину, строго формализованную и включающую в себя различные математические методы, теории и анализ случайных процессов. Идеи о понятии распределения вероятностей возникли ещё в 17-ом веке у Пьера де Ферма и Блеза Паскаля, но основополагающую работу в этой области сделал Абрахам де Муавр в 18-ом веке, опубликовав 1733 году свою работу под названием «Доклад о шансах», в которой впервые применил анализ и статистику для описания случайных событий и введения понятия распределения вероятностей. Он показал, как можно использовать биномиальное распределение для приближения вероятности великого числа независимых случайных испытаний.

Окончательно теория вероятностей как математическая наука оформилась в 30-х годах 20-го века, когда Андреем Николаевичем Колмогоровым была предложена аксиоматическое определение вероятности. Колмогоров также формализовал понятие случайной величины и установил строгие математические основы для изучения вероятностных явлений. С помощью теории вероятностей стало возможным описывать случайные величины и их распределения.

Одно из наиболее изучаемых распределений случайных величин в теории вероятностей – нормальное распределение, также известное как распределение

Гаусса, названное в честь математика Карла Фридриха Гаусса, который изучил его основные свойства в 18-ом веке, например то, что нормальное распределение подходит для моделирования большого количества случайных процессов. В частном случае, когда известна только выборка, но неизвестна генеральная совокупность, такую модификацию нормального распределения называют распределением Стьюдента или t-распределением.

Темой данной курсовой работы является распределение Стьюдента, тесно связанное с нормальным распределением. Целью работы является изучение свойств этого распределения и решение практических задач, с ним связанных. Актуальность исследования распределение Стьюдента обоснована тем, что оно более устойчиво к выбросам и отклонениям от среднего значения в сравнении с нормальным, а значит может более эффективно использоваться в качестве инструмента для моделирования и анализа случайных процессов в теории вероятностей и математической статистике.

# 1 Случайная величина и её характеристики

## 1.1 Одномерная случайная величина

Понятие случайной величины играет важную роль в теории вероятностей и является ключевым инструментом, позволяющим формально описывать случайные явления и их вероятностные свойства. **Одномерная случайная величина** — это скалярная функция, определенная на пространстве элементарных событий, сопоставляющая каждому элементарному событию число или, иначе говоря, это величина, значение которой зависит от того, каким элементарным событием закончился случайный опыт [1]. Случайные величины обозначаются заглавными буквами латинского алфавита, например  $X, Y, Z$ . Среди общепринятых обозначений можно выделить также  $N$ , которое часто используется для обозначения случайной величины, имеющей нормальное (гауссово) распределение, и  $T$ , которое используется для обозначения распределения Стьюдента (t-распределение).

Под **элементарным исходом** или элементарным событием  $\omega$  понимается любой простейший, то есть неразделимый в контексте рассматриваемого опыта, исход. Множество всех возможных значений или результатов случайного эксперимента называют **пространством элементарных исходов** и обозначают символом  $\Omega$ . Иначе говоря, множество исходов опыта образует пространство элементарных исходов, если верно следующее [2]:

- в результате опыта один из исходов обязательно происходит;
- появление одного из исходов исключает появление всех прочих;
- в рамках данного опыта элементарных исход неразделим.

Более строго данную связь можно выразить следующим образом:  $\omega \in \Omega$ , а множество  $\Omega = \{\omega_1, \omega_2, \dots, \omega_n, \dots\} = \{\omega_i, i = 1, 2, \dots, n, \dots\}$ . Чтобы задать некоторую случайную величину  $X$ , необходимо поставить в соответствие каждому элементарному исходу  $\omega_i$  числовое значение  $x_i$ , которое случайная величина примет, если в результате опыта произойдет именно этот исход.

Например, если каждому элементарному исходу  $\omega_i$ ,  $i = 1, \dots, n$ , ставится в соответствие число  $i$ , то получим случайную величину, определяемую следующим образом (таблица 1):

Таблица 1 – Соответствие между элементарными исходами  $\omega$  и значениями  $X$

$\omega$	$\omega_1$	$\omega_2$	...	$\omega_n$
$X$	1	2	...	$n$

Таким образом, скалярную функцию  $X(\omega)$ , заданную на пространстве элементарных исходов  $\Omega = \{\omega_1, \omega_2, \dots, \omega_n, \dots\}$ , и называют случайной величиной, если для любого  $x \in \mathbb{R}$  множество  $\{\omega: X(\omega) < x\}$  элементарных исходов, удовлетворяющих условию  $X(\omega) < x$ , является событием.

Случайные величины могут быть разделены на **дискретные**, то есть такие, которые принимают набор отдельных изолированных значений (конечное (счётное) или бесконечное число), или **непрерывные**, набор значений которых целиком заполняет некоторый интервал [3].

Основной характеристикой случайных величин является **закон распределения случайной величины**, также называемый распределением её вероятностей. Общим законом распределения и для дискретных, и для непрерывных случайных величин является **функция распределения** – функция  $F(x)$  для случайной величины  $X$ , значение которой в точке  $x$  равно вероятности события  $\{X < x\}$ , то есть события, состоящего из тех и только тех элементарных исходов  $\omega$ , для которых  $X(\omega) < x$ :

$$F(x) = P \{X < x\}$$

Типичный вид функции распределения приведён на рисунке 2.




Рисунок 2 – Вид графика функции распределения

Из того факта, что функция распределения – это вероятность, следует, что она обладает следующими свойствами:

- 1) Функция распределения – это неубывающая функция:  $F(x_1) < F(x_2)$  при  $x_1 < x_2$ ;
- 2) Множество значений принадлежит отрезку  $[0, 1]$ , откуда следует, что  $F(-\infty) = 0, F(+\infty) = 1$ ;
- 3) Вероятность попадания в интервал  $(x_1, x_2)$  можно определить следующим образом:  $P\{x_1 \leq X \leq x_2\} = F(x_2) - F(x_1)$ ;

Законом распределения дискретной случайной величины  $X$  называют таблицу, состоящую из двух строк, в одной из которых перечислены все возможные значения случайной величины, а во второй – вероятности  $p_i$ , что случайная величина  $X$  примет эти значения, то есть  $p_i = P\{X = x_i\}$ . При этом  $\sum_{i=1}^n p_i = 1$ , то есть сумма по строке вероятностей должна равняться единице [2]. Общий вид закона распределения дискретной случайной величины приведён в таблице 2.

Таблица 2 – Закон распределения дискретной случайной величины в общем виде

$X$	$x_1$	$x_2$	...	$x_i$	...	$x_n$
$P$	$p_1$	$p_2$	...	$p_i$	...	$p_n$



График функции распределения дискретной случайной величины представлен на рисунке 3. График представляет собой ступенчатую линию, где каждая ступень соответствует возможному значению случайной величины, а её высота (высота скачка в данной точке) определяет вероятность возникновения этого значения.




Рисунок 3 – График функции распределения дискретной случайной величины

Для непрерывной случайной величины  $X$  функцию распределения  $F(x)$  можно выразить с помощью **функции плотности распределения**  $f(x)$  следующим образом:

$$f(x) = F'(x)$$

Из этого следует, что функцию  $f(x)$  можно называть дифференциальным законом распределения непрерывной случайной величины, а  $F(x)$  – интегральным, причём для этих законов верно следующее:

$$F(x) = \int_{-\infty}^x f(x)dx$$

Функция плотности обладает следующими свойствами:

- 1)  $f(x) \geq 0$ , поскольку  $F(x)$  не убывает;
- 2)  $\int_{-\infty}^{+\infty} f(x)dx = 1$ ;
- 3) Вероятность попадания в интервал  $(x_1, x_2)$  можно определить следующим образом  $P\{x_1 \leq X < x_2\} = \int_{x_1}^{x_2} f(x)dx$ ;
- 4)  $P\{X = x\} = 0$ .

График функции плотности распределения приведён на рисунке 4. Согласно свойству 3, площадь криволинейной трапеции, обозначенной на рисунке штриховкой, равна вероятности попадания непрерывной случайной величины в полуинтервал  $[x_1, x_2)$ . Аналогичным образом в силу свойства 2 площадь под всей кривой распределения равна единице.




Рисунок 4 – График функции плотности распределения непрерывной случайной величины

## 1.2 Основные виды распределения случайных величин

Среди наиболее часто встречающихся на практике распределений можно выделить следующие [2]:

1. **Биномиальное распределение** дискретной случайной величины, задаваемое следующим образом:  $P_n(i) = C_n^i p^i q^{n-i} = (p + q)^n$ , где  $i = 0, 1, \dots, n$ . Его закон распределения приведён в таблице 3.

Таблица 3 – Ряд биномиального распределения

$X$	0	1	...	$i$	...	$n$
$P$	$q^n$	$C_n^1 p q^{n-1}$	...	$C_n^i p^i q^{n-i}$	...	$p^n$

2. **Распределение Пуассона** дискретной случайной величины, определяемое следующим образом:  $P\{i, \lambda\} = \frac{\lambda^i}{i!} e^{-\lambda}$ , где  $i = 0, 1, \dots, n, \dots$ ,

а  $\lambda > 0$  – параметр распределения Пуассона. Его закон распределения приведён в таблице 4.

Таблица 4 – Ряд распределения Пуассона

$X$	0	1	2	...	n	...
$P$	$e^{-\lambda}$	$\lambda e^{-\lambda}$	$\frac{\lambda^2}{2} e^{-\lambda}$	...	$\frac{\lambda^n}{n!} e^{-\lambda}$	...

3. **Равномерное распределение** непрерывной случайной величины, плотность распределения которой определяется выражением:

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & x \notin [a, b] \end{cases}$$

Исходя из того факта, что  $F(x) = \int_{-\infty}^x f(x)dx$ , закон распределения равномерного распределения записывается следующим образом:

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & x \in [a, b] \\ 1, & x > b \end{cases}$$

Графики обеих функций представлены на рисунке 5.

А)

Б)





Рисунок 5 – График функции: а) плотности равномерного распределения; б) закона равномерного распределения

4. **Экспоненциальное распределение** непрерывной случайной величины, функция плотности распределения которого имеет параметр  $\lambda$  и определяется как:

$$f(x) = \begin{cases} 0, & x < 0 \\ \lambda e^{-\lambda x}, & x \geq 0 \end{cases}$$

Случайная величина, распределённая по экспоненциальному (показательному) закону, имеет функцию распределения вида:

$$F(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$$

Графики данных функций представлены на рисунке 6.




Рисунок 6 – График функции: а) плотности показательного распределения; б) закона показательного распределения


5. **Нормальное распределение** непрерывной случайной величины, функция плотности распределения которого имеет вид:

$$\varphi_{m,\sigma}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-m)^2}{2\sigma^2}}, (-\infty < m < +\infty, \sigma > 0)$$

Как показано на рисунке 7, данное распределение, в частности, вид его графика, зависит от двух параметров –  $m$  и  $\sigma$ . Его закон распределения записывается следующим образом:

$$\Phi_{m,\sigma}(x) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{(x-m)^2}{2\sigma^2}} dx$$

А)



Б)




Рисунок 7 – График функции: а) плотности распределения Гаусса; б) закона распределения Гаусса

### 1.3 Распределение Стьюдента

Распределение Стьюдента (или t-распределение) используется для моделирования случайных величин, когда имеется ограниченное количество наблюдений и некоторая неопределенность в данных. Распределение Стьюдента получило свое название в честь псевдонима, используемого Уильямом Сили Госсетом, который в начале 20-го века внёс значительный вклад в решение проблемы, связанной с оценкой среднего значения на основе ограниченного количества наблюдений [4]. Вопрос, которым занимался Стьюдент, был связан с построением так называемых **доверительных интервалов** – диапазонов значений, в которых с определённой вероятностью содержится истинное значение параметра генеральной совокупности (например, среднего значения). Ранее для этого использовалось распределение Гаусса, однако при малом объеме выборки ( $n \leq 30$  наблюдений) и неизвестном стандартном отклонении генеральной совокупности, использование нормального распределения становилось неточным – с этим и столкнулся Госсет, а после разработал распределение, основанное на t-статистике, которое позволяло делать более точные оценки и строить доверительные интервалы при использовании малых выборок и неизвестного стандартного отклонения генеральной совокупности. Он опубликовал свои исследования под псевдонимом «Стьюдент», откуда и произошло название распределения.

**Распределением Стьюдента (t-распределением)** называют распределение, функция плотности вероятности которого имеет вид:

$$f(x) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu} * \Gamma\left(\frac{1}{2}\right) \Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}},$$

где  $X$  – случайная величина,  $\nu$  – число степеней свободы и  $\Gamma(f)$  – гамма-функция.

Под гамма-функцией понимается гамма-функцией Эйлера – специальная функция в математике, введённая Леонардом Эйлером для обобщения понятия факториала на комплексные и действительные числа. Она имеет вид: [5]

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx$$

Гамма-функция определена для всех комплексных чисел с положительной вещественной частью, то есть для  $\alpha > 0$ . Одним из интересных свойств гамма-функции является возможность применения к ней так называемой формулы понижения [5]:

$$\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$$

Это позволяет вычислять значения гамма-функции для разных аргументов, используя уже известные значения. Эйлерова гамма-функция также обладает симметрией, поэтому к ней применима формула отражения:

$$\Gamma(z) * \Gamma(1 - z) = \pi / \sin(\pi z)$$

Формула отражения позволяет вычислять значения гамма-функции для отрицательных аргументов или аргументов, удаленных от положительных целых чисел. В контексте теории вероятностей гамма-функция играет важную роль в определении и вычислении функций распределения и плотности распределения некоторых случайных величин, в частности, распределения Стьюдента. Гамма-функция входит в функцию плотности распределения Стьюдента через отношение  $\frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu} * \Gamma\left(\frac{1}{2}\right) \Gamma\left(\frac{\nu}{2}\right)}$ . Это отношение возникает из применения гамма-функции

для нормировки t-статистики, которая определяется как отношение выборочного среднего и стандартной ошибки. Используя гамма-функцию, мы нормируем t-статистику, чтобы получить функцию плотности распределения Стьюдента.

Как видно из формулы функции распределения, t-распределение имеет один параметр, называемый **степенью свободы** распределения Стьюдента. Степень свободы влияет на ширину и форму распределения и является мерой количества независимых наблюдений, используемых для оценки распределения. Чем больше степень свободы, тем ближе t-распределение приближается к нормальному. При этом, при меньшей степени свободы, распределение имеет более плоскую форму.

График функции t-распределения, то есть **кривая распределения Стьюдента** имеет колоколообразную форму, напоминающую нормальное распределение, но с более тяжёлыми «хвостами». При  $n > 30$  распределение стремится к нормальному закону распределения. На рисунке 8 показан график функции t-распределения при значениях  $\nu_1 = 1, \nu_2 = 5, \nu_3 > 20$ .




Рисунок 8 – График функции плотности t-распределения с числом степеней свободы  $\nu_1 = 1, \nu_2 = 5$  и  $\nu_3 > 20$

**Функция распределения** t-распределения в общем случае имеет вид:

$$F(x) = \int_{-\infty}^x f(x)dx$$

Она не имеет аналитического решения в данном случае, поэтому для вычисления её значений часто используются таблицы или специальные программы. Её график схож с графиком функции распределения нормального распределения, как показано на рисунке 9:




Рисунок 9 – График функции распределения t-распределения

Числовые характеристики распределения Стьюдента зависят от его степени свободы  $\nu$ :

1. **Математическое ожидание** t-распределения определено и равно нулю при любом  $\nu > 2$ :

$$M = 0, \quad \nu > 2$$

2. **Дисперсия** t-распределения определяется следующей формулой:

$$D = \frac{\nu}{\nu - 2}, \quad \nu > 2$$

3. **Среднеквадратичное отклонение** t-распределения равно квадратному корню из дисперсии, то есть:

$$\sigma = \sqrt{\frac{\nu}{\nu - 2}}, \quad \nu > 2$$



4. **Центральный момент**  $t$ -распределения  $n$ -го порядка определяется следующим образом:

$$\mu_n = \begin{cases} 0, & n = 2 * k + 1, k \in Z \\ \left(\frac{\nu}{\nu - 2}\right)^{\frac{n}{2}} * \frac{\nu - 2}{(\nu - 4)!!}, & n = 2 * k, k \in Z, \nu > 4 \end{cases}$$

5. **Начальный момент** для  $t$ -распределения с  $\nu$  степенями свободы не имеет аналитической формулы для  $n \geq \nu$ . Это связано с тем, что функция плотности вероятности  $t$ -распределения не интегрируется аналитически для степеней выше  $\nu$ , а данная характеристика вычисляется численными методами или аппроксимациями.

6. **Мода** равна значению  $f(x)$  при  $x = 0$ .

7. **Медиана**  $t$ -распределения также равна нулю.

Для анализа точности оценок статистических параметров на основе выборочных данных можно использовать формулу для **вероятности попадания случайной величины  $X$  в доверительный интервал**  $(x_{\frac{\alpha}{2}}, x_{1-\frac{\alpha}{2}})$ , которая выглядит следующим образом:

$$P\left(x_{\frac{\alpha}{2}} < X < x_{1-\frac{\alpha}{2}}\right) = 1 - \alpha,$$

где  $\alpha$  – вероятность отклонения результатов эксперимента от нулевой гипотезы при условии, что она верна. Для нахождения значения **уровня значимости**  $\alpha$  необходимо знать уровень доверия для построения доверительного интервала. Уровень доверия обычно задается в процентах и представляет собой вероятность того, что истинное значение параметра лежит внутри построенного доверительного интервала. Например, для уровня доверия 95% соответствующее значение  $\alpha$  будет равно 0.05, так как это означает, что необходимо рассмотреть только 5% случаев, когда истинное значение параметра лежит за пределами доверительного интервала, а в остальных 95% случаев это

значение лежит внутри этого интервала. Формула для нахождения уровня значимости может быть выражена следующим образом:

$$\alpha = \frac{1 - \text{уровень доверия (\%)}}{100}.$$

Если среднее значение выборки попадает в заданный доверительный интервал (то есть интервал, вероятность попадания среднего значения выборки в который определена заранее), то мы не можем отвергнуть нулевую гипотезу о том, что различия между двумя выборками статистически не значимы на уровне значимости 5%. Для того чтобы отклонить нулевую гипотезу и доказать статистическую значимость различий между двумя выборками, среднее значение выборки должно выходить за пределы заданного доверительного интервала [6].

Одним из важных понятий, связанных с t-распределением, является *t-статистика* – мера различия между двумя выборками данных. Она часто используется в статистических тестах гипотез, чтобы определить, является ли различие между выборками значимым или случайным. Если t-статистика больше критического значения, то можно сделать вывод о статистически значимом различии между выборками. Она может быть определена как отношение оценки параметра модели к её стандартной ошибке. В этом случае формула будет иметь вид:

$$t = \frac{b - \beta}{SE(b)},$$

где  $b$  – оценка параметра модели (числовое значение, которое определяет взаимосвязь между независимыми и зависимыми переменными в рамках выбранной модели),  $\beta$  – истинное значение параметра модели, а  $SE(b)$  – стандартная ошибка оценки параметра модели.

Существует некоторое значение, которое разделяет вероятностное распределение Стьюдента на две области и называется оно *квантилем*. Выражаясь более формально, t-квантиль уровня  $\alpha$  – это такое число  $t_\alpha$ , для

которого вероятность  $P(T < t_\alpha) = \alpha$ , где  $T$  представляет распределение Стьюдента с  $n$  степенями свободы [7]. Квантиль порядка  $p$  также записывают как  $Q(p)$ .

В контексте задач систематизации и обработки результатов наблюдений массовых случайных явлений для выявления существующих закономерностей необходимо рассмотреть такое понятие, как **совокупность всех подлежащих изучению объектов** или возможных результатов наблюдений, проводимых в неизменных условиях над одним объектом, называется генеральной совокупностью. Выборочной совокупностью или **выборкой** называется совокупность объектов, отобранных случайным образом из генеральной совокупности. Число объектов в совокупности называется ее объемом. Считается, что объем генеральной выборки бесконечен. Конкретные значения выборки, полученные в результате наблюдений, называют реализацией выборки и обозначают  $x_1, x_2, \dots, x_n$ .

## 2 Применение t-распределения при решении практических задач

Среди задач, в которых для решения используется t-распределение, можно выделить следующие наиболее практически значимые:

- **Оценка среднего значения** генеральной совокупности при неизвестной дисперсии: если известен только размер выборки и выборочное среднее значение, то можно использовать распределение Стьюдента для оценки значимости различий между выборочным и генеральным средним.
- **Расчет доверительного интервала для среднего значения** генеральной совокупности: распределение Стьюдента также позволяет вычислить доверительный интервал для среднего значения генеральной совокупности с известной точностью.
- **Оценка статистической значимости** различий между двумя выборками: если известны средние значения и стандартные отклонения двух выборок, то можно использовать распределение Стьюдента для проверки гипотезы о равенстве этих средних значений.
- **Оценка коэффициента корреляции**: если известны выборочные коэффициенты корреляции и размер выборки, то можно использовать распределение Стьюдента для проверки гипотезы о значимости корреляции.
- **Оценка параметров линейной регрессии**: распределение Стьюдента используется для проверки гипотезы о значимости коэффициентов линейной регрессии при небольшом размере выборки.

Рассмотрим далее несколько конкретных примеров задач, решение которых связано с t-распределением и t-статистикой Стьюдента.

## 2.1 Оценка среднего значения генеральной совокупности

**Задача.** Оценить средний рост студентов в университете среди случайным образом выбранных 10 студентов. Данные выборки  $X = [170, 165, 172, 168, 175, 172, 169, 171, 173, 170]$  [8]

**Решение.** Среднее значение выборки вычислим по формуле:

$$\bar{X} = \frac{\sum_{i=1}^n x_i}{n} = \frac{170 + 165 + 172 + 168 + 175 + 172 + 169 + 171 + 173 + 170}{10} = 170.5.$$

Таким образом, средний рост студентов в выборке равен 170.5 см. Следом вычислим стандартное отклонение выборки:

$$s = \sqrt{\sum \frac{(x_i - \bar{X})^2}{n - 1}} \approx 2.4314.$$

Следующим шагом будет вычисление значения стандартной ошибки среднего по формуле:

$$SE = \frac{s}{\sqrt{n}} = \frac{2.4314}{\sqrt{10}} \approx 0.7687.$$

Получим, что значение стандартной ошибки среднего составляет примерно 0.7687 см. При надежности 95% уровень значимости  $\alpha = 0.05$  и число степеней свободы  $\nu = n - 1 = 9$ . Из таблиц получаем значение t-критерия, равное 2,262. Теперь нам необходимо определить доверительный интервал  $CI$ , который показывает, с какой вероятностью истинное среднее значение генеральной совокупности находится в заданном интервале. Для вычисления доверительного интервала нам необходимо использовать формулу:

$$CI = \bar{X} \pm t * SE = 170.5 \pm 2$$

Мы получили, что доверительный интервал составляет  $170.5 \pm 2.306 * 0.7687$ , что равно (169.24, 173.76). Таким образом, с 95% вероятностью мы можем утверждать, что истинное среднее значение роста студентов в университете находится в этом интервале.

**Ответ:** оценка среднего роста студентов в университете среди случайно выбранных 10 студентов со 95% вероятностью лежит в интервале (169.24, 173.76).

## ***2.2 Использование t-распределения для вычисления вероятности***

**Задача.** Найти вероятность того, что случайная величина  $X$  с десятью степенями свободы лежит в пределах  $(1,5 < X < 2)$  [9].

**Решение.** Известно, что  $\nu = 10$ . Для решения задачи необходимо сначала перейти от случайной величины  $X$  к соответствующей ей случайной величине  $t_{10}$  с распределением Стьюдента. По таблицам t-распределения найдём вероятности соответствующих интервалов  $(1,372 < t_{10} < 1,812)$  и  $(1,812 < t_{10} < 2,228)$ .

$$P_1 = P(1,372 < t_{10} < 1,812) = 0,05$$

$$P_2 = P(1,812 < t_{10} < 2,228) = 0,025$$

Для распределения Стьюдента со степенями свободы  $\nu$  существует также таблица значений, которая позволяет найти квантили  $Q(p)$  порядка  $p$  для определенных значений  $\nu$  и уровня значимости  $\alpha$ . Исходя из них в данном случае уровень значимости  $\alpha = 0,05$ . Теперь необходимо найти значения t-статистики для интервалов, соответствующих квантилям  $Q(0,025)$  и  $Q(0,975)$ . Находим, что первый из них  $Q(0,025)$  соответствует t-статистике, равной 1,812, а  $Q(0,975)$  соответствует t-статистике, равной 2,228.

Наконец, для вычисления искомой вероятности необходимо привести интервал  $(1,5 < X < 2)$  к виду  $(\alpha < t_{10} < \beta)$ , где  $\alpha$  и  $\beta$  соответствуют найденным значениям t-статистики. Для этого используется формула линейной интерполяции и искомую вероятность можно вычислить путем взвешенного среднего вероятностей попадания в каждый из интервалов при условии, что случайная величина находится в интервале  $(1,5 < X < 2)$ :

$$P(1,5 < X < 2) = 0,05 * \left( \frac{1,812 - 1,5}{1,812 - 1,372} \right) + 0,025 * \left( \frac{2 - 1,812}{2,228 - 1,812} \right) \approx 0,047.$$

**Ответ:** 0,047.

### ***2.3 Задача об оценке статистической значимости (анализ регрессии)***

**Задача.** Были случайным образом выбраны 8 учеников, для которых получены следующие выборки:

время на домашнюю работу (в часах)  $X = [2, 4, 3, 1, 5, 6, 7, 8]$ ;

результаты экзамена (в баллах)  $Y = [60, 70, 65, 55, 75, 80, 85, 90]$ .

Необходимо оценить зависимость между количеством времени, проведенным на дому за учебой, и результатами экзамена по математике [10].

**Решение.** Для оценки параметров линейной регрессии используем распределение Стьюдента. Тогда искомая модель будет иметь вид:  $y = b_0 + b_1 * x$ , где  $b_0$  и  $b_1$  – неизвестные коэффициенты, которые необходимо найти.

Сперва найдем по известным формулам для каждой переменной такие характеристики, как выборочное среднее и стандартное отклонение:

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{2 + 4 + 3 + 1 + 5 + 6 + 7 + 8}{8} = 4.125$$

$$\bar{y} = \frac{\sum_{i=1}^n y_i}{n} = \frac{60 + 70 + 65 + 55 + 75 + 80 + 85 + 90}{8} = 73.75$$

$$s_x = \sqrt{\sum_{i=1}^n \frac{(x_i - \bar{x})^2}{n - 1}} = 2.439$$

$$s_y = \sqrt{\sum_{i=1}^n \frac{(y_i - \bar{y})^2}{n - 1}} = 11.44552$$

Затем рассчитаем выборочный коэффициент корреляции  $r$  между  $x$  и  $y$ :


$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{s_x * s_y} = 0.86195$$

Теперь мы можем получить оценки коэффициентов  $b_0$  и  $b_1$ :

$$b_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}} \approx 9.28458$$

$$b_0 = \bar{y} - b_1 * \bar{x} = 35.00724$$

Таким образом, наша модель линейной регрессии будет иметь вид  $y = 35.00724 + 9.28458 * x$ . Графически это выглядит следующим образом:



Проверим значимость коэффициента наклона  $b_1$  с помощью t-теста. Для этого нужно рассчитать значение t-статистики по формуле:

$$t = \frac{b_1 - 0}{SE(b_1)} = \frac{b_1 \sqrt{\sum (x_i - \bar{x})^2}}{SE_{res}} = 5.309$$

Значение t-статистики соответствует уровню значимости  $p = 0.0013$  при числе степеней свободы  $n - 2 = 6$ . Это означает, что полученный коэффициент наклона является статистически значимым.

**Ответ:**  $b_1 = 9.28458$  является статистически значимым.



## **2.4 Проверка гипотезы о среднем значении показателя в генеральной совокупности**

**Задача.** Дана выборка из 10 наблюдений. Необходимо проверить гипотезу о том, что среднее значение показателя в генеральной совокупности равно 50. Известно, что стандартное отклонение в выборке составляет 5, а выборочное среднее равно 48 [8].

**Решение.** Тогда для проверки гипотезы используется t-критерий Стьюдента. Формула для расчета значения t-статистики имеет вид:

$$t = \frac{(\bar{x} - \mu)\sqrt{n}}{s} = \frac{(48 - 50)\sqrt{10}}{5} \approx -1.41$$

Далее нам необходимо найти критическое значение t-статистики для заданного уровня значимости и числа степеней свободы. В данном случае число степеней свободы равно  $\nu = n - 1 = 9$ . Положим, что уровень значимости  $\alpha = 0.05$ . Тогда критическое значение t-статистики можно найти с помощью таблицы распределения Стьюдента  $t_{\text{крит}} = \pm 2.262$ .

$$|t| = |-1.41| < 2.262.$$

Следовательно, мы не можем отвергнуть гипотезу о равенстве среднего значения 50 на уровне значимости  $\alpha = 0.05$ .

**Ответ:** гипотеза верна.

## **2.5 Задача о проверке гипотезы о значимости коэффициента регрессии**

**Задача.** Проверить гипотезу о значимости коэффициента регрессии для независимой переменной  $x$  при уровне значимости  $\alpha = 0,05$  для следующих данных [8]:  $n = 10$ ,  $x = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]$ ,  $y = [1, 3, 2, 5, 7, 8, 8, 9, 10, 12]$ .

**Решение.** Мы хотим проверить гипотезу о значимости коэффициента регрессии для независимой переменной, то есть проверить, является ли

коэффициент значимым или нет. Пусть у нас есть гипотеза  $H_0: \beta_1 = 0$  (нулевая гипотеза), где  $\beta_1$  – коэффициент регрессии для независимой переменной  $x$ . Альтернативная ей гипотеза  $H_a: \beta_1 \neq 0$ . Таким образом задача сводится к проверке, является ли коэффициент регрессии  $\beta_1$  значимым. Для проверки можно воспользоваться t-статистикой Стьюдента:

$$t = \frac{b_1 - 0}{\frac{s}{\sqrt{n - 2}}}$$

Где  $b_1$  – оценка коэффициента регрессии для  $x$ ,  $s$  – среднеквадратическое отклонение резидуальных ошибок,  $n$  – число наблюдений.

Найдем оценку коэффициента регрессии  $b_1$  и среднеквадратическое отклонение  $s$  следующим образом:

$$b_1 = \sum_{i=1}^{10} \frac{(x_i - \bar{x})(y_i - \bar{y})}{(x_i - \bar{x})^2} \approx 1.1697$$

$$s = \sqrt{\frac{\sum_{i=1}^{10} (x_i - \bar{x})^2}{n - 1}} \approx 1,7845$$

И, наконец, определим t-статистику Стьюдента:

$$t = \frac{1.1697}{\frac{1,7845}{\sqrt{8}}} = 4,238$$

Согласно табличным данным, на уровне значимости  $\alpha = 0,05$  и степеней свободы  $n - 2 = 8$  критическое значение t-статистики равно 2,306. Так как вычисленное значение  $4,238 > 2,306$ , то есть оно больше критического, то мы можем отвергнуть нулевую гипотезу о том, что коэффициент регрессии равен нулю на уровне значимости  $\alpha = 0,05$ . То есть, можно сделать вывод о том, что найденный коэффициент регрессии  $b_1$  статистически значимо отличается от нуля и имеет влияние на зависимую переменную  $y$ .

**Ответ:** существует статистически значимая связь между зависимой переменной  $y$  и независимой переменной  $x$ .

## Заключение

В ходе выполнения данной курсовой работы был рассмотрен такой раздел теории вероятностей, как случайные величины и их распределения, в частности, t-распределение Стьюдента – изучены его основные свойства и общие характеристики. Также были рассмотрены основные виды практических статистических и вероятностных задач, связанных с t-распределением, а также приведено решение нескольких примеров таких задач.

Можно заключить, что благодаря работе Уильяма Госсета и его вкладу в разработку распределения Стьюдента, статистики и исследователи получили важный инструмент, позволяющий делать более точные оценки и строить доверительные интервалы при работе с ограниченными выборками данных. Это имеет важное значение в различных областях, где доступ к большим объемам данных ограничен или невозможен.

## Список использованных источников

1. Феллер В. Введение в теорию вероятностей и ее приложения. В 2-х томах. Т. 1: Пер. с англ. – М.: Мир, 1984. – 528 с.
2. Печинкин А.В., Тескин О.И., Г.М. Цветкова и др.; Под ред. Зарубина В.С., Крищенко А.П. Теория вероятностей: Учеб. для вузов. - 3-е изд., испр. изд. – М.: Изд-во МГТУ им. Н.Э. Баумана, 2004. - 456 с.
3. Теория вероятностей и математическая статистика: учеб. пособие / Е. А. Трофимова, Н. В. Кисляк, Д. В. Гилёв; [под общ. ред. Е. А. Трофимовой ; М-во образования и науки Рос. Федерации, Урал. федер. ун-т. – Екатеринбург: Изд-во Урал. ун-та, 2018. – 160 с.
4. Гнеденко Б.В. Курс теории вероятностей: Учебник. – Изд. 8-е., испр. и доп. изд. – М.: Едиториал УРСС, 2005. – 448 с.
5. Зорич В. А. Математический анализ. Часть II. — Изд. 9-е, испр. — М.: МЦНМО, 2019. — xii+676 с. Библ.: 57 назв. Илл.: 41.
6. Понятие t-распределения в тестах на статистическую значимость // RadioProg URL: <https://radioprogram.ru/post/930> (дата обращения: 21.05.2023).
7. Фишер Р. Applications of «Student's» distribution (англ.) // metron. – 1925. – Vol. 5. – P. 90 – 104.
8. Леман, Э.Л. Проверка статистических гипотез / перевод с англ. Ю.В. Прохорова. – 2-е изд., испр. – М.: Наука, 1979. – 408 с.
9. Поллард. Д. Справочник по вычислительным методам статистики / Дж. Поллард; Перевод с англ. В. С. Занадворова. – М.: Финансы и статистика, 1982. – 344 с.
10. Кобзарь А.И. Прикладная математическая статистика [Текст]: для инженеров и науч. работников / А. И. Кобзарь. – Изд. 2-е, испр. – Москва : Физматлит, 2012. – 813 с.